Programa de Estudios

MINERÍA DE DATOS

Código	: DOA_0006_CA01
Periodo Académico	: Segundo semestre 2025
Créditos	: 6
Requisito	: Ninguno
Horario	: Jueves de 16:00 a 18:15 hrs. (GMT -04:00, Santiago, Chile)
Profesor(es)	: Dr. Bastián González-Bustamante (bastian.gonzalez.b@mail.udp.cl)
Ayudante(s)	: Camila Luardo (camila.luardo@mail.udp.cl)

Última actualización: 17 de agosto de 2026

I. DESCRIPCIÓN

En este curso de minería de datos, los estudiantes aprenderán a procesar grandes volúmenes de datos para tomar decisiones informadas en diferentes tipos de organizaciones y realizar investigaciones en ciencias sociales. La minería de datos es un proceso fundamental para obtener conocimientos valiosos a partir de los datos que nos rodean. Al analizar y modelar estos datos, podemos identificar patrones y tendencias que nos permiten tomar decisiones más efectivas y mejorar procesos en áreas como el marketing, la gestión de recursos humanos y la investigación social en general.

Durante este curso, los estudiantes aprenderán conceptos básicos de minería de datos relacionados con la limpieza y el procesamiento de datos, técnicas de imputación, detección de valores atípicos, control de versiones con Git y análisis exploratorio y de clústeres. Además, se profundizará en el modelamiento predictivo mediante algoritmos y árboles de decisión, técnicas de ensamblaje de modelos, así como en una breve aproximación al procesamiento del lenguaje natural (Natural Language Processing, NLP) y a los grandes modelos de lenguaje (Large Language Models, LLMs) para la clasificación y el análisis de datos.

Se empleará la metodología de Aprendizaje Basado en Investigación (ABR), en la que los estudiantes abordarán un problema central mediante investigaciones individuales. Al finalizar este curso, los estudiantes habrán desarrollado las habilidades necesarias para procesar y analizar grandes volúmenes de información y estarán capacitados para aplicar estos conocimientos en distintos contextos.

II. OBJETIVOS

Al final del curso se espera que los y las estudiantes sean capaces de:

- Identificar y describir las etapas fundamentales del proceso de minería de datos, incluyendo la recopilación, limpieza, transformación y análisis de datos.
- Identificar y modelar las diferentes tareas de minería de datos (e.g., tareas descriptivas, predictivas, etc.).
- Aplicar técnicas y modelos de aprendizaje automático de distintos tipos.
- Evaluar y comparar diferentes técnicas y modelos de aprendizaje automático.

III. HABILIDADES RECOMENDADAS

- Conocimientos básicos de estadística.
- Nociones básicas de programación en Python.
- Conceptos fundamentales de bases de datos.
- Nivel intermedio-avanzado de lectura en inglés.

IV. METODOLOGÍA Y ESTRATEGIA DE EVALUACIÓN

El curso contempla una sesión semanal de 2 horas y 15 minutos, que incluye un breve descanso intermedio. Durante esta sesión se pueden programar diversas actividades, como clases expositivas, talleres prácticos o tutorías personalizadas.

El curso contempla una estrategia de evaluación diversa e integral. Todas las evaluaciones son **individuales**. En primer lugar, se realizará un estudio de caso que representará el 20% de la evaluación del curso. Luego, se llevará a cabo un desafío de predicción, que funciona como un taller práctico de minería de datos y representa el 30% de la evaluación final. Los desafíos de años anteriores pueden revisarse en GitHub:

- https://github.com/Doctorado-UDP/data-mining-2024/tree/main/prediction_challenge
- https://github.com/Doctorado-UDP/data-mining-2025/tree/main/prediction_challenge

Finalmente, los estudiantes trabajarán en mini-proyectos de minería de datos que les permitirán aplicar conceptos aprendidos a problemas reales. Cada estudiante definirá una pregunta de investigación original y desarrollará un proyecto que la aborde, lo que implicará recopilar y analizar datos relevantes, establecer objetivos y métricas para evaluar el éxito del proyecto y diseñar las etapas necesarias para alcanzarlos. Los mini-proyectos serán evaluados según lo siguiente: informe de resultados (20%), presentación en clase (10%), coevaluación entre pares (10%) y autoevaluación del estudiante (10%).

Para cada entrega, se recomienda, **cuando sea posible**, subir al GitHub del curso (https://github.com/Doctorado-UDP/data-mining-2026) lo siguiente: bases de datos utilizadas, códigos en Python y/o R e informes en LaTeX y/o Markdown.

Esta estrategia de evaluación permitirá ofrecer retroalimentación constructiva y personalizada a cada estudiante, lo que contribuirá a mejorar su comprensión y sus habilidades en minería de datos.

V. CRONOGRAMA DE TRABAJO

Sesión 1. Introducción al curso y minería de datos
► Jueves 20 de agosto de 2026

La clase comenzará con una breve introducción al curso, a la minería de datos, su relación con el aprendizaje automático y su relevancia en el mundo actual. Además, esta sesión presentará las diferentes etapas del proceso de minería de datos e investigación: definición del problema, recopilación de datos, procesamiento, modelado, evaluación y despliegue, y las relacionará con las áreas de la investigación social.

Sesión 2. Revisión de control de versiones con Git y herramientas de producción de contenido con LaTeX y Markdown
► Jueves 27 de agosto de 2026

En esta sesión se introducirán las herramientas relevantes para los procesos de minería y análisis de datos, incluyendo Git como sistema de control de versiones y LaTeX y Markdown como herramientas de producción de contenido.

Sesión 3. Análisis exploratorio de datos
► Jueves 3 de septiembre de 2026

Esta sesión se centrará en el análisis exploratorio de datos, abarcando temas como la descripción y manipulación de diferentes tipos de datos, técnicas de limpieza y de procesamiento, imputación de valores faltantes, detección y tratamiento de valores atípicos, entre otros.

Sesión 4. Modelamiento descriptivo
► Clase recuperativa, fecha por determinar
Encuesta: https://savvycal.com/p/udp/recuperacion-data-mining-2026

Esta sesión se centrará en tareas de minería de datos orientadas al análisis descriptivo, incluyendo técnicas no supervisadas de aprendizaje automático y de clustering. Se explorarán diferentes enfoques para entender la estructura y patrones en los datos

Sesión 5. Presentación de estudio de caso y análisis de ejemplos de minería de datos exitosos
► Jueves 24 de septiembre de 2026

En esta sesión, los estudiantes seleccionarán un caso real en el que se haya aplicado con éxito la minería de datos y deberán preparar un estudio de caso detallado. **Puede ser un artículo publicado, un proyecto o una aplicación real.** El análisis incluirá el problema identificado, las etapas del proceso de minería de datos empleadas, las técnicas y herramientas utilizadas, así como los resultados obtenidos.

Cada estudiante presentará su estudio de caso durante la sesión, seguido de una reflexión crítica sobre posibles mejoras en la aplicación y sobre otros enfoques que podrían haberse utilizado (**20% de la nota final del curso**). La presentación debe durar **15 minutos**. Esta discusión generará interés y conexión entre la teoría y la práctica, permitiendo a los estudiantes analizar casos reales y aprender de las experiencias de sus compañeros.

Considerando la cantidad de inscritos en el curso, es posible que las presentaciones se extiendan a la siguiente sesión.

Sesión 6. Introducción a los algoritmos de aprendizaje automático supervisado
► Jueves 1 de octubre de 2026

En esta sesión se llevará a cabo una introducción exhaustiva y detallada al aprendizaje automático supervisado. Se explorarán los conceptos fundamentales de este tipo de machine learning, incluyendo la definición de problemas de clasificación y regresión, la selección de parámetros y la preparación de los datos para el entrenamiento de los modelos.

Sesión 7. Tareas de clasificación con algoritmos y modelos de aprendizaje automático I
► Jueves 8 de octubre de 2026

En esta sesión, los estudiantes aprenderán sobre el modelado predictivo mediante algoritmos de clasificación. Se explorarán diferentes enfoques para resolver problemas de clasificación, como la regresión logística y Naive Bayes. Los estudiantes también aprenderán a elegir entre estos algoritmos según las características del problema y los datos disponibles.

Sesión 8. Tareas de clasificación con algoritmos y modelos de aprendizaje automático II
► Jueves 15 de octubre de 2026

En esta sesión, los estudiantes aprenderán sobre el modelamiento predictivo en tareas de clasificación mediante algoritmos más complejos. Se explorarán aproximaciones para resolver problemas de clasificación, incluyendo árboles de decisión, Support Vector Machine (SVM) y redes neuronales, como Extreme Gradient Boosting (XGBoost). Los estudiantes también aprenderán a elegir entre estos algoritmos según las características del problema y los datos disponibles.

Sesión 9. Métricas de evaluación de modelos de aprendizaje automático
► Jueves 22 de octubre de 2026

En esta sesión se presentará un panorama amplio de las métricas de evaluación de modelos utilizadas en el aprendizaje automático. Se explorarán diferentes métricas para evaluar el rendimiento de los modelos, incluyendo precisión, recall y F1-score, así como otros métodos de evaluación más complejos, como k-fold cross-validation.

Además, se analizarán ejemplos prácticos de cómo utilizar estas métricas para comparar el desempeño de distintos modelos en problemas reales. El objetivo es proporcionar una

comprensión profunda de las técnicas de evaluación y de su aplicación efectiva en la minería de datos.

Sesión 10. Ensamblado de modelos y técnicas avanzadas de predicción
► Jueves 29 de octubre de 2026

En esta sesión se explorarán estrategias para ensamblar modelos y mejorar su rendimiento. Los estudiantes aprenderán a combinar distintos modelos para obtener una predicción más robusta. Además, se presentarán técnicas avanzadas de predicción, como las ventanas móviles (rolling windows) y el ajuste de hiperparámetros (hyperparameter tuning), que permiten adaptar los modelos a distintos contextos y problemas.

También se analizarán ejemplos prácticos de cómo ensamblar modelos mediante técnicas como bagging, boosting y stacking. Se discutirán las ventajas y desventajas de cada enfoque y se presentará un panorama general de la selección del más adecuado para diferentes problemas de minería de datos.

Sesión 11. Desafío de predicción
► Jueves 5 de noviembre de 2026

En esta sesión se presentará el desafío de predicción, que funcionará como un taller práctico y permitirá aplicar las habilidades adquiridas durante el curso a un problema real. Los desafíos de años anteriores pueden revisarse en GitHub:

- https://github.com/Doctorado-UDP/data-mining-2024/tree/main/prediction_challenge
- https://github.com/Doctorado-UDP/data-mining-2025/tree/main/prediction_challenge

Los estudiantes deberán utilizar el conjunto de datos que se proporcionará para entrenar y validar sus propios modelos de aprendizaje automático en Python. Se presentará un script base que los estudiantes podrán refinar y utilizar para entrenar y preparar sus propios modelos supervisados. Diariamente se actualizará la tabla de clasificación (leaderboard) con los nuevos modelos preparados por los estudiantes.

Los estudiantes deben entrenar al menos un modelo durante el desafío y pueden realizar como máximo un envío por día. Otras cuestiones logísticas relacionadas con los datos (e.g., límite de predictores, tipos de recodificación, etc.) serán comunicadas durante esta sesión.

El desafío representa un **30% de la evaluación final del curso**, y la nota se calculará con base en el mejor F1-score obtenido por cada estudiante, considerando todos los envíos realizados a través de GitHub. El desafío durará **dos semanas**.

Sesión 12. Text-as-Data y NLP para análisis de datos
► Jueves 12 de noviembre de 2026

En esta sesión, exploraremos aproximaciones para analizar grandes volúmenes de texto como si fueran conjuntos de datos numéricos. Descubriremos cómo utilizar técnicas de procesamiento de lenguaje natural (NLP, por sus siglas en inglés) para convertir textos en formatos manejables, y luego aprenderemos a aplicar algoritmos de minería de datos a estos conjuntos textuales. También exploraremos herramientas y librerías para automatizar el procesamiento del lenguaje natural y mejorar la extracción de información valiosa de textos en Python.

Sesión 13. Modelos semi-supervisados y clasificación con LLMs
► Jueves 19 de noviembre de 2026

En esta sesión, profundizaremos, aunque de forma introductoria, en los modelos semi-supervisados y su aplicación en la clasificación de textos. Aprenderemos a utilizar transformadores como BERT y RoBERTa y grandes modelos de lenguaje (LLMs, por sus siglas en inglés) para mejorar el rendimiento de algoritmos de clasificación en problemas de minería de datos. Luego aplicaremos estos conceptos en ejercicios prácticos.

Sesión 14. Mini-Proyectos de aplicación en minería de datos
► Jueves 26 de noviembre de 2026

En esta sesión, los estudiantes comenzarán a trabajar en mini-proyectos de minería de datos que les permitan aplicar los conceptos aprendidos durante el curso a problemas reales. Cada estudiante definirá una pregunta de investigación original y desarrollará un proyecto que aborde dicha pregunta. Esto implicará recopilar y analizar datos relevantes, establecer objetivos y métricas para evaluar el éxito del proyecto, y diseñar las etapas necesarias para alcanzarlos.

Durante la sesión, los estudiantes recibirán retroalimentación constructiva sobre sus proyectos en curso, lo que les permitirá ajustar su enfoque y mejorar su plan de trabajo.

Como en versiones anteriores del curso, la sesión semanal será reemplazada por reuniones personales con cada estudiante. Estas reuniones podrán agendarse en el horario normal del curso o en otro horario de oficina de acuerdo con la disponibilidad del profesor.

Sesión 15. Desarrollo del proyecto de minería de datos
► Jueves 3 de diciembre de 2026

En esta sesión, los estudiantes continuarán trabajando en sus mini-proyectos, aplicando las habilidades y herramientas aprendidas durante el curso para desarrollarlos. El objetivo es realizar la preparación de datos, el modelado y la exploración inicial de los resultados.

Durante la sesión, los estudiantes recibirán retroalimentación constructiva sobre su progreso. Se revisarán algunos de los obstáculos enfrentados y se sugerirán ajustes para mejorar el proceso para todos los estudiantes. Al finalizar la sesión, cada estudiante deberá mostrar el progreso alcanzado hasta el momento y recibir retroalimentación valiosa sobre su trabajo en curso.

Como en versiones anteriores del curso, la sesión semanal será reemplazada por reuniones personales con cada estudiante. Estas reuniones podrán agendarse en el horario normal del curso o en otro horario de oficina de acuerdo con la disponibilidad del profesor.

Sesión 16. Presentación de proyectos de minería de datos
► Jueves 10 de diciembre de 2026

Antes de la sesión, los estudiantes deben entregar un informe detallado sobre los resultados de su mini-proyecto y respaldar el código y datos en GitHub **si es posible**. Esto representa el **20% de la evaluación final del curso**. Durante la sesión, cada estudiante presentará su proyecto a la clase, demostrando su proceso de análisis, sus resultados y sus conclusiones. Cada presentación tendrá un límite de 20 minutos, seguida de una sesión de preguntas y respuestas en la que el resto de la clase podrá plantear dudas o comentarios, lo cual representa el **10% de la evaluación final del curso**.

Además, se incentivará a los estudiantes a incluir consideraciones sobre el impacto en el campo de estudio y su relevancia práctica en el contexto real. Se les pedirá a los estudiantes que completen una coevaluación de sus pares (**10% de la evaluación final del curso**) y una autoevaluación de su proyecto (**10% de la evaluación final del curso**).

Considerando la cantidad de inscritos en el curso, es posible que las presentaciones se extiendan a la siguiente sesión.

Sesión 17. Cierre y análisis retrospectivo del curso
► Jueves 17 de diciembre de 2026

En esta sesión, los estudiantes tendrán la oportunidad de recapitular todos los conceptos aprendidos en las sesiones anteriores. Se realizará un análisis retrospectivo del curso, revisando los conceptos clave aprendidos y reflexionando sobre cómo pueden aplicarse en el contexto académico o profesional. Esta sesión finalizará con una visión general de las

posibilidades y oportunidades que ofrece la minería de datos en diversos campos y sectores, preparando a los estudiantes para su integración laboral o su perfeccionamiento académico.

VI. BIBLIOGRAFÍA

- Argyle, L. P., Busby, E. C., Fulda, N., Gubler, J. R., Rytting, C., & Wingate, D. (2023). Out of One, Many: Using Language Models to Simulate Human Samples. *Political Analysis, 31*(3), 337-351.
- Barrie, C., Palaiologou, E., & Törnberg, P. (2024). *Prompt Stability Scoring for Text Annotation with Large Language Models*. arXiv preprint, Cornell University.
- Gilardi, F., Alizadeh, M., & Kubli, M. (2023). ChatGPT outperforms crowd workers for text-annotation tasks. *Proceedings of the National Academy of Sciences, 120*(30), e2305016120.
- González-Bustamante, B. (2024). *Benchmarking LLMs in Political Content Text-Annotation: Proof-of-Concept with Toxicity and Incivility Data*. arXiv preprint, Cornell University.
- González-Bustamante, B. (2026). Machine Learning and Political Events: Application of a Semi-supervised Approach to Produce a Dataset on Presidential Cabinets. *Social Science Computer Review, 44*(2), 245-258.
- Grimmer J., & Stewart B. M. (2013). Text as data: The promise and pitfalls of automatic content analysis methods for political texts. *Political Analysis, 21*(3), 267-297.
- Grimmer, J., Roberts, M. E., & Stewart, B. M. (2022). *Text as Data: A News Framework for Machine Learning and the Social Sciences*. Princeton University Press.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning. Data Mining, Inference, and Prediction, 2nd Edition*. Springer.
- Hvitfeldt, E., & Silge, J. (2022). *Supervised Machine Learning for Text Analysis in R*. CRC Press.
- Spirling, A. (2023). Why open-source generative AI models are an ethical way forward for science. *Nature, 616*(7957), 413-413.
- Tan, P.-N., Steinbach, M., & Kumar, V. (2018). *Introduction to Data Mining, 2nd edition*. Pearson.
- Timoneda, J. C., & Vallejo Vera, S. (2025). BERT, RoBERTa or DeBERTa? Comparing Performance Across Transformer Models in Political Science Text. *The Journal of Politics, 87*(1), 347-364.
- Törnberg, P. (2023). *ChatGPT-4 Outperforms Experts and Crowd Workers in Annotating Political Twitter Messages with Zero-Shot Learning*. arXiv preprint, Cornell University.

VII. PROFESOR Y HORARIO DE OFICINA

Dr. Bastián González-Bustamante. Profesor Asociado en la Facultad de Administración y Economía de la Universidad Diego Portales. Investigador Asociado del Grupo de Ciencia Política Computacional de la Universidad de Oxford, Reino Unido. Investigador postdoctoral en Ciencias Sociales Computacionales en la Facultad de Gobernanza y Asuntos Globales de la Universidad de Leiden, Países Bajos. Doctor (DPhil/PhD) en Ciencia Política por la Universidad de Oxford, Reino Unido. Magíster en Ciencia Política, Administrador Público y Licenciado en Ciencias Políticas y Gubernamentales por la Universidad de Chile.

Web: https://bgonzalezbustamante.com
Email: bastian.gonzalez.b@mail.udp.cl

Si desea programar una reunión personal, puede hacerlo con un plazo de hasta **24 horas de anticipación**, siempre que exista disponibilidad:

- https://savvycal.com/udp/meetings